Proyecto Final Sistemas de Recuperación de la Información

Alejandro Campos, Darian Dominguez

Facultad de Matemática y Computación
Universidad de la Habana
2021

Resumen

En el mundo de hoy se tiene acceso a mucha información. Sería muy complicado para una persona buscar, entre millones y millones de documentos, cuáles serían útiles y relevantes para su objetivo. Los sistemas de recuperación de la información facilitan este trabajo. Estos reciben una consulta por parte del usuario y procesan toda la colección de documentos, que luego de analizarlos y representarlos de una forma que el sistema entiende, devuelven en un corto período de tiempo aquellos archivos más relevantes a la petición del usuario.

I. Introducción

Realizar búsquedas de información es una actividad diaria en todos los ambientes que reviste especial importancia. En áreas de investigación es una actividad que puede insumir un tiempo importante entre operaciones que van desde: definir los criterios, iniciar la búsqueda, filtrar los resultados, encontrar la información y luego tenerla a disposición de una manera clasificada y ordenada. La fase de búsqueda se inicia sobre las expectativas planteadas por el investigador y finaliza cuando el mismo encuentra finalmente el o los documentos que poseen la información de interés. [1]

Varios documentos pueden responder a la consulta del usuario, por ello, los sistemas implementan un ranking de documentos ordenados según la relevancia a la petición del usuario, dependiendo del modelo sobre los que son implementados. Existen discímiles modelos para recuperar información, estos se diferencian en la manera de representar los documentos y la consulta, en dependencia de los términos que la conforman. A partir de esta forma de representación, se le asocia a cada documento un valor calculado mendiante una función de ranking, que varía en dependencia del modelo utilizado.

Este informe tiene como objetivo describir el diseño, implementación, evaluación y análisis de un Sistema de Recuperación de Información.

II. Diseño del sistema

Luego del estudio y análisis de los modelos estudiados en [2], se decidió usar el modelo vectorial para el desarrollo del sistema de recuperación de la información. En la presente sección se explicarán los motivos de esta selección, no sin antes explicar en qué consiste este modelo.

Brevemente, según este modelo, cada documento es representado mediante un vector de n elementos, siendo n igual al número de términos indizables que existen en la colección documental. Hay, pues, un vector para cada documento, y, en cada vector, un elemento para cada término o palabra susceptible de aparecer en el documento. Cada uno de esos elementos es cubierto u ocupado con un valor numérico. Si la palabra no está presente en el documento, ese valor es igual a 0. En caso contrario, ese valor es calculado teniendo en cuenta diversos factores, dado que una palabra dada puede ser más o menos significativa (tanto en general como, sobre todo, en ese documento en concreto); este valor se conoce con el nombre de peso del término en el documento. Las consultas son representadas también mediante un vector de las mismas características que las de los documentos. Esto permite calcular fácilmente una función de similaridad dada entre el vector de una consulta y los de cada uno de los documentos.[3]

El modelo vectorial es ampliamente usado en operaciones de recuperación de información, así como también en operaciones de categorización automática, filtrado de información, etc. Aunque tiene la desventaja de asumir independencia de términos, el cálculo del valor asociado a cada documento para realizar el ranking se determina por la cercanía de este con respecto a la consulta del usuario, definida por el coseno del ángulo entre el vector que representa al documento y el de la consulta. Podemos decir, además, que el esquema de ponderación de este modelo (tf-idf como se verá posteriormente) permite un mejor rendimiento en la recuperación de información.

III. Implementación del sistema

El sistema se ha implementado usando el lenguaje de programación python, cuyas bibliotecas ofrecen facilidades para el trabajo con el procesamiento textual. La implementación se encuentra en la carpeta **code**. En las siguientes subsecciones se explica el uso de cada uno de los módulos más importantes del sistema.

I. Procesamiento textual

En el módulo `text_processing.py` se realizan todas las fases del preprocesamiento textual, tokenización, normalización, lematización o reducción de las palabras a su raíz gramatical y eliminación de stopwords. Para esto se usó la librería *nltk*.

II. Representación de documentos y consultas

`representation.py` provee métodos para la representación de documentos y consultas. En este se calcula el tf de cada término en cada documento, así como idf de cada término y, a través de estos, se determina el peso de cada término i en el documento j (w_{ij}). Se precisan a continuación cada uno de los términos anteriores.

$$tf_{ij} = \frac{freq_{ij}}{max_i freq_{ij}}$$

donde el numerador corresponde a la cantidad de veces que se repite el término i en el documento j, y el denominador es la cantidad de veces que se repite el término que más se repite en el documento j. También se tiene que

$$idf_i = log\frac{N}{n_i}$$

donde N corresponde a la cantidad total de documentos de la colección y n_i a la cantidad de documentos en los que aparece el término

i. Finalmente, el peso de un término en el documento, viene dado por

$$w_{ij} = tf_{ij} * idf_i$$

. Como ya se dijo, los documentos son represantados como vectores, cuyas componentes vienen dadas por los pesos de los términos que aparecen en estos.[4]

Las consultas también son representadas como vectores, el peso de un término en la consulta q viene dado por

$$w_{iq} = (a + (1 - a)tf_{ij}) * idf_i$$

donde a usualmente toma valor 0.4 o 0.5 [4]. Notemos que si a = 0 el peso de la consulta es el mismo que el del documento.

III. Documentos

Las colecciones de documentos se encuentran en la carpeta "docs". El sistema trabajará con la colección de archivos con extensión .txt localizados en dicha ruta. En `document_processing.py` se procesan todos los documentos de la colección. A sus textos se les realiza el procesamiento textual y se calcula el peso de cada término resultante en cada documento.

IV. Función de similitud

El módulo `sim.py` contiene el cálculo de la función de similitud, mediante la cual se realiza el ranking de los documentos. Acorde al modelo empleado, esta función se calcula como el coseno del ángulo comprendido entre el vector que representa cada uno de los documentos y la consulta.

$$sim(d_j, q) = \frac{\vec{d_j}\vec{q}}{|\vec{d_j}||\vec{q}|},$$

esto es

$$sim(dj, q) = \frac{\sum_{i=1}^{n} w_{ij} w_{iq}}{\sqrt{\sum_{i=1}^{n} w_{ij}^2} \sqrt{\sum_{i=1}^{n} w_{iq}^2}}$$

[4]

V. Procesamiento de consulta y devolución de resultados

Al texto de la consulta se le realiza un preprocesamiento, como se expuso en la sección correspondiente. Luego se le calcula el peso de cada término para formar el vector consulta, a partir del cual la función de similitud le asocia un valor a cada documento y devuelve el ranking de estos, a partir de un umbral que se define previamente. Esto se realiza en `query_processing.py`.

VI. Expansión de consulta

El sistema implementa la expansión de consulta, lo cual permite expandir las consultas ingresadas por el usuario a fin de ampliar el espectro de las búsquedas que se realicen. El módulo `query_expansion.py` implementa esta funcionalidad, donde por cada término t de la consulta, esta es expandida automáticamente con sinónimos y palaras relacionadas con t.

VII. Clustering

Los documentos se agrupan según su similitud de acuerdo al contenido que presentan. El módulo `clustering.py` utiliza el algoritmo k-means con este fin. De esta forma el usuario recibe la colección de documentos agrupados por tópicos, lo cual es de utilidad para explorar documentos similiares a los devueltos como resultado en la consulta, y explorar los documentos de aquellos temas que le resulten de interés. Para seleccionar el número de clusters para agrupar los documentos se usa el método del codo, cuya impementación se encuentra, también, en dicho módulo.

IV. Modelo booleano

Con el fin de comparar el sistema desarrollado, se implementó otro modelo: el modelo booleano. Este modelo se basa en la teoría de conjuntos y el álgebra booleana para devolver los resultados [4]. En este modelo las consultas están diseñadas como expresiones booleanas que tienen una semántica precisa y, considera

solo si los términos indexados están presentes o ausentes en un documento. La estrategia de recuperación se basa en un criterio de decisión binario.

En el módulo `boolean_model.py` se encuentra la implementación de este modelo. Luego del preprocesamiento del texto de los documentos, estos se expresan como vectores binarios atendiendo a la presencia o no de términos indexados. Posteriormente, despúes del preprocesamiento y expansión de la consulta, esta se convierte en una expresión booleana de tal forma que si el término t_q de la consulta está presente en los términos indexados, entonces la componente correspondiente al término es 1, en otro caso toma valor 0.

Con la representación booleana abordada anteriormente, la función de similitud en este modelo devuelve aquellos documentos que "se parezcan más" a la consulta, es decir, aquellos documentos que tengan más componentes en común con esta.

V. Interfaz de usuario. Manual de usuario

Para la interfaz de usuario se usó la librería *flask* que permite crear aplicaciones web rápidamente, usando html y css.

Al abrir la aplicación se mostrará la pantalla de presentación como se muestra a continuación:

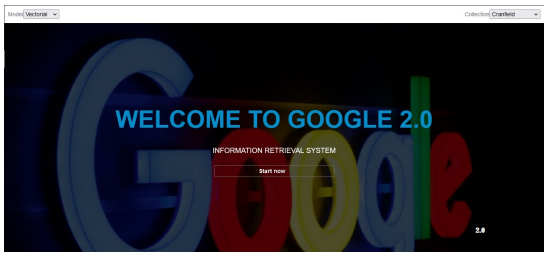

Donde en la esquina superior derecha se podrá escoger para procesar entre varias colecciones de documentos predefinidas o crear alguna perzonalizada.

En la esquina superior izquierda se podrá escoger el modelo con el cual se desea procesar la colección.

Una vez definidos los parámetros anteriores mediante el botón *Start now* comienza el procesamiento de la colección seleccionada con el modelo escogido. Cuando la coleción se haya procesado se muestra la siguiente pantalla:

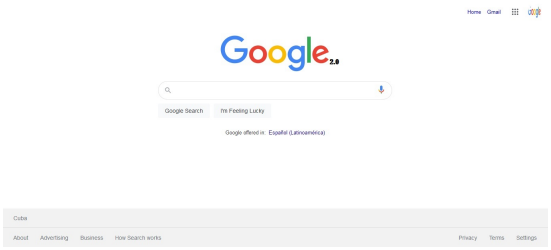

En la barra de búsqueda se inserta la consulta de interés para el usuario y se da enter para obtener los resultados. El botón home regresa a la pantalla de portada. Los resultados se muestran de la siguiente manera:

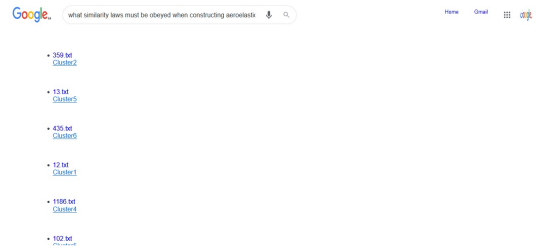

Si se da click encima del nombre del documento se muestra su contenido, además se observa que cada documento tiene asociado un tópico o tema, y dando click sobre este se listan todos los documentos relacionados con este tema, por si el usuario muestra interés por algún otro documento de este tópico.

Para ejecutar la aplicación es necesario tener un navegador web. Junto a este informe se provee un .exe que ejecuta la aplicación, con extensión para linux y windows. Se debe aclarar que en Windows para cerrar la aplicación y que no se quede corriendo el servidor en el puerto, debemos salir presionando Ctrl+c en la consola que se abre junto a la aplicación. En Linux, escribiendo en consola `sudo kill (sudo lsof -t -i:3000)`.

VI. Evaluación del sistema

Para evaluar un sistema es necesario utilizar colecciones de prueba, las cuales contienen los documentos y, además, información acerca de los documentos relevantes para un conjunto de consultas. Las pruebas utlizadas para evaluar el presente sistema son las colecciones de Cranfield y Medline, que se encuentran en **code/collections/**. El módulo `evaluation.py` se encarga de procesar los documentos y las consultas de cada una de las colecciones antes mencionadas, devolviendo las métricas estudiadas durante el curso de SRI, que nos permitirán evaluar el sistema implementado.

Es importante aclarar que, dado el tamaño que presentan las colecciones, el proceso de evaluación se demora considerablente, ya que procesa los documentos para dos modelos, además de un gran número de consultas.

I. Métricas utilizadas

En [5] se proponen varias métricas para evaluar un sistema de recuperación de la información y, para un mejor entendimiento de sus fórmulas se aclaran las siguientes notaciones:

1. **REL** conjunto de documentos relevantes
2. **REC** conjunto de documentos recuperados
3. **RR** conjunto de documentos relevantes recuperados
4. **NN** conjunto de documentos no relevantes no recuperados
5. **RI** conjunto de documentos recuperados irrelevantes
6. **NR** conjunto de documentos no recuperados relevantes

[5]

Las medidas usadas son las siguientes:

- Precisión.

$$P = \frac{|RR|}{|RR \cup RI|} = \frac{|RR|}{|REC|}$$

Esta medida evalúa la consulta de acuerdo a los documentos relevantes que se recuperan[5]. Despuées de tener los documentos que fueron recuperados en la consulta, se buscan cuáles son relevantes con ayuda de la información brindada por la colección, y teniendo esto, se aplica la fórmula. Este proceso se realizó para cada consulta de la colección y los resultados obtenidos fueron promediados.

- Recobrado.

$$R = \frac{|RR|}{|RR \cup RN|} = \frac{|RR|}{|REL|}$$

fracción de los documentos relevantes que fueron recuperados[5]. Con ayuda de la información que brinda la colección se buscan los documentos relevantes para la consulta, teniendo ya los documentos recuperados se va analizando de estos, cuáles son relevantes, e igualmente se aplica la fórmula. El proceso se realiza para cada consulta de la colección y los resultados obtenidos se promedian.

- Medida F.

$$F = \frac{(1+\beta^2)PR}{\beta^2 P + R} = \frac{(1+\beta^2)}{\frac{1}{P} + \frac{\beta^2}{R}}$$

enfatiza la precisión sobre el recobrado o viceversa[5]. Igualmente, el proceso se realiza para cada consulta de la colección y los resultados obtenidos se promedian.

- Medida F1.

$$F1 = \frac{2PR}{P+R} = \frac{2}{\frac{1}{P} + \frac{1}{R}}$$

armoniza precisión y recobrado teniendo en cuenta a ambos.[5] Para su cálculo se usó la precisión y el recobrado, previamente calculados, y se aplicó la fórmula. Igualmente, el proceso se realiza para cada consulta de la colección y los resultados obtenidos se promedian.

- R-Presición.

$$P_R = \frac{|RR|_R}{|RR \cup RI|_R} = \frac{|RR|_R}{|REC|_R}$$

  es el ranking de documentos relevantes a una consulta para la cual existen R documentos relevantes[5]. Para su cálculo se seleccionaron los primeros R documentos recuperados y de estos se vieron cuáles son relevantes, de acuerdo a la información que brinda la colección y se aplica la fórmula. El proceso se realiza para cada consulta de la colección y los resultados obtenidos se promedian.

- Fallout

$$Fallout = \frac{|RI|}{|RI \cup NI|} = \frac{|RI|}{|I|}$$

  tiene en cuenta la cantidad de documentos irrelevantes y el ranking [5]. Se puede calcular la cardinalidad del conjunto de los documentos recuperados irrelevantes con la diferencia de los documentos recuperados y de los recuperados relevantes. Por otro lado, con la diferencia del total de documentos y los documentos relevantes, se tiene el conjunto de los documentos irrelevantes; luego, se aplica la fórmula y se repite el proceso para cada consulta de la colección y los resultados se promedian.

II. Análisis de los resultados obtenidos

Para mostrar los resultados de la evaluación del método booleano y el vectorial en dos escenarios distintos, se debe abrir la consola en el directorio del proyecto y ejecutar `python evaluation.py` Esto ejecutará ambos modelos sobre las colecciones de Cranfield y Medline[6], mostrando el cálculo de las medidas de evaluación abordadas en la sección anterior. En el caso de las medidas que tienen en cuenta el ranking, se tomarán los primeros 10 documentos.

En un primer escenario, la colección Cranfield, se cuenta con 1400 documentos y 225 consultas, en la que, luego de aplicar el modelo vectorial se arribaron a los siguientes resultados:

Si se fija un umbral de 0.08:

```
Precision Average:  0.1094814814814815
Recall Average:  0.644597701149425287
F (beta = 0) Average:  0.1094814814814814
F1 Average:  0.18602870470039468962
R-precision Average:  0.250044444444444447
Fallout Average:  0.031425460436968326
```

Como se observa, se tiene una precisión baja y un recobrado relativamente alto, lo cual puede estar dado porque se devuelven muchos documentos como resultado a las consultas. Si se prueba con un umbral más elevado, 0.15, se tiene que

```
Precision Average:  0.17667238645741274
Recall Average:  0.081436161800807733
F (beta = 0) Average:  0.17667238645741
F1 Average:  0.0989109335636531973
R-precision Average:  0.0853634000283629
Fallout Average:  0.0128324467540477802
```

En este caso los valores son bajos, lo que puede estar dado porque se devuelven muy pocos documentos como resultado a consultas. Si se fija un umbral que se encuentre en el centro de los dos valores, los resultados deben mejorar. Se debe buscar un equilibrio en el que no sea abrumadora la cantidad de documentos que se devuelven, ni muy poca. Si se ejecutan las evaluaciones con un umbral del 0.11 se obtiene:

```
Precision Average:  0.57987467891626214
Recall Average:  0.439855042462559
F (beta = 0) Average:  0.57987467891626
F1 Average:  0.45654982088860464
R-precision Average:  0.5628909908643447
Fallout Average:  0.005557089650605272
```

Se observa que la precisión y el recobrado

oscilan sobre los mismos valores, entre 0.4 y 0.6, los cuales son valores buenos, que indican que el sistema devuelve los resultados esperados. Las otras medidas también son buenas, lo que ratifica que lo expresado anteriormente.

Si en este escenario aplicamos el modelo booleano, con un límite de documentos resultantes de 40, se obtiene que:

```
Precision Average:  0.0966402407556727
Recall Average:  0.205010479814852074
F (beta = 0) Average:  0.0966402407556
F1 Average:  0.12414552678756908
R-precision Average:  0.3022575531659254
Fallout Average:  0.05332300012708674
```

Se observa un muy bajo valor de precisión, lo que puede estar dado por la cantidad de documentos que se devuelven. El recobrado es relativamente bajo, así como las otras medidas. Se intentará ahora con un valor de 10 documentos resultantes como límite.

```
Precision Average:  0.115019878494544
Recall Average:  0.035371411909860904
F (beta = 0) Average:  0.115019878494544
F1 Average:  0.0471018653142009
R-precision Average:  0.056069958150249385
Fallout Average:  0.021353375534192
```

En este caso las medidas son muy bajas, por lo que el modelo no esta devolviendo los resultados esperados. Si se fija un valor de 25 documentos como límite, se obtiene:

```
Precision Average:  0.43725477494339827
Recall Average:  0.38781951274405562
F (beta = 0) Average:  0.43725477494339827
F1 Average:  0.409038370028197194
R-precision Average:  0.41934086302500142
Fallout Average:  0.007953313599142427
```

En este caso las medidas tienen valores relativamente altos, siendo la precisión la más elevada. Estos valores no están mal, si bien no son ideales, indican que el sistema, con el modelo booleano, devuelve algunos resultados que satisfacen las necesidades del usuario.

Si ejecutamos el sistema sobre la colección de Medline, se tiene que, para el modelo vectorial implementado, se obtienen los siguientes resultados:

Si se fija un umbral de 0.08

```
Precision Average:  0.095555400507532
Recall Average:  0.61641704263402854
F (beta = 0) Average:  0.095555400507532
F1 Average:  0.0621209195982305
R-precision Average:  0.16541951566913747
Fallout Average:  0.06254018467969548
```

Como se observa, se tiene una precisión baja y un recobrado relativamente alto, lo cual puede estar dado porque se devuelven muchos documentos como resultado a las consultas. Si se prueba con un umbral más elevado, 0.15, se tiene que

```
Precision Average:  0.260371458963389
Recall Average:  0.0642323967561534
F (beta = 0) Average:  0.260371458963
F1 Average:  0.103046485092519685
R-precision Average:  0.07570631341196
Fallout Average:  0.0457742784840535
```

En este caso los valores son bajos, lo que puede estar dado porque se devuelven muy pocos documentos como resultado a consultas. Si se fija un umbral que se encuentre en el centro de los dos valores, los resultados deben mejorar. Se debe buscar un equilibrio en el que no sea abrumadora la cantidad de documentos que se devuelven, ni muy poca. Si se ejecutan las evaluaciones con un umbral del 0.11 se obtiene:

```
Precision Average:  0.530371458963389
Recall Average:  0.5042323967561534
F (beta = 0) Average:  0.5303714589633
F1 Average:  0.63046485092519685
```

```
R-precision Average:  0.0757063134119
Fallout Average:  0.0057742784840535
```

En este caso los resultados son muy buenos, se obtuvo una precisión alta, al igual que el recobrado. Lo que indica que la mayoría de los documentos recuperados fueron relevantes. El resto de las medidas también fueron muy buenas.

Si en este escenario aplicamos el modelo booleano, con un límite de documentos resultantes de 40, se obtiene que:

```
Precision Average:  0.07711344455390836
Recall Average:  0.175527036341846
F (beta = 0) Average:  0.07711344455390836
F1 Average:  0.10809409640170624
R-precision Average:  0.2863479703627805
Fallout Average:  0.07002101566858976
```

En esta ocasión se devuelven demasiados documentos, lo cual se ve reflejado en los valores anteriores. Se observa un muy bajo valor de precisión, lo que puede estar dado por la cantidad de documentos que se devuelven. El recobrado es relativamente bajo, así como las otras medidas. Se intentará ahora con un valor de 10 documentos resultantes como límite.

```
Precision Average:  0.157913591314895
Recall Average:  0.0526228257992206
F (beta = 0) Average:  0.157913591314895
F1 Average:  0.0780621041862924
R-precision Average:  0.06366182045593243
Fallout Average:  0.03506911904879048
```

En este caso las medidas son muy bajas, lo que puede venir dado por la poca cantidad de documentos que devuelve el modelo, además, no está devolviendo los resultados esperados. Si se fija un valor de 25 documentos como límite, se obtiene:

```
Precision Average:  0.4075456344647778
Recall Average:  0.3685410468103969
F (beta = 0) Average:  0.4075456344647778
F1 Average:  0.3870973090372418
R-precision Average:  0.3970972693403497
Fallout Average:  0.0868155098017147
```

Finalmente, el modelo booleano en este escenario se comporta de una forma relativamente bien. Las medidas tienen valores relativamente altos, siendo la precisión la más elevada. Estos valores no están mal, si bien no son ideales, indican que el sistema, con el modelo booleano, devuelve algunos resultados que satisfacen las necesidades del usuario en este escenario.

VII. Ventajas y desventajas del sistema

El sistema implementado presenta varias ventajas, entre las que se pueden mencionar que las métricas usadas en la sección anterior para la evaluación del sistema dan resultados favorables. Devuelve resultados satisfactorios a las necesidades que el usuario define a través de consultas. Además, presenta funcionalidades como expansión de consulta, agrupamiento de documentos por tópicos o clustering y una interfaz de usuario amigable para la inserción de las consultas y mostrar los resultados.

Como desventaja se puede decir que el sistema solo trabaja localmente en una dirección escpogida con el usuario, además, el procesamiento de documentos demora un poco, sobre todo en colecciones grandes con documentos extensos.

VIII. Conclusiones

El sistema implementado presenta buenos resultados. Realizar un sistema de recuperación de información es un proceso trabajoso que lleva asociado un proceso de análisis y estudio. Aún así el presente sistema

responde de manera positiva en los escenarios donde se realizó el proceso de evaluación.

En ambos escenarios, con los parámetros indicados, el sistema obtuvo buenas métricas. Lo que quiere decir que procesa los documentos y la consulta del usuario de manera satisfactoria, devolviendo resutados de interés para el usuario. El modelo vectorial demostró ser mejor que el booleano en ambos escenarios, lo que puede venir dado porque los documentos no tenían la consulta de forma explícita en su texto, a pesar de que la expansión de consulta ayuda mucho al modelo booleano a devolver mejores resultados, no logró superar al otro modelo implementado. Ambos modelos mostraron patrones similares en ambos escenarios, dando resultados favorables.

IX. Recomendaciones y trabajo futuro

Al sistema se le pueden añadir un conjunto de mejoras para que funcione de manera óptima, y agregar nuevas funcionalidades para devolver mejores resultados, entre las que se encuentran:

- Añadir retroalimentación.
- Optimizar el procesamiento de documentos
- Añadir crawling como sistema de recuperación en la web

X. Bibliografía

[1] http://sedici.unlp.edu.ar/bitstream/handle/10915/43840/ Documento_completo.pdf?sequence=1&isAllowed=y

[2] Conferencias 2 y 3 SRI para la carrera de Ciencia de la Computación, Universidad de La Habana. Curso 2022

[3] https://bid.ub.edu/04figue2.htm

[4] Conferencia 2 SRI para la carrera de Ciencia de la Computación, Universidad de La Habana. Curso 2022

[5] Conferencia 4 SRI para la carrera de Ciencia de la Computación, Universidad de La Habana. Curso 2022

[6] http://ir.dcs.gla.ac.uk/resources/test_collections/

2